频繁项集与关联规则挖掘

吴韬略*

中国科学技术大学 大数据学院, 合肥

【摘 要】 本次实验实现 FP-growth 算法,以支持度和置信度作为阈值寻找频繁项集,挖掘关联规则。并计算了对应的 lift, PS, coefficient 值。

【关键词】 频繁项集,关联规则, FP-growth

1 数据预处理

数据预处理步骤同实验三, 选取与 REPEAT 列相关系数最大的五个特征:

['ST001D01T', 'ISCEDL', 'ST005Q01TA', 'ST013Q01TA', 'EVERE0 - 1']

其中, 'EVERE0-1' 是实验三中自己构建的特征。定义如下:

$$['EVERE'] = ['ST127Q01TA'] + ['ST127Q02TA'] + ['ST127Q03TA']$$

$$['EVERE0 - 1'] = \begin{cases} 0, ['EVERE'] < column \, ['EVERE'] \, .mean \\ 1, ['EVERE'] \geqslant column \, ['EVERE'] \, .mean \end{cases}$$

然后查询 codebook 将选取的特征名换为直观表示其含义的名字:

$$'EVERE0 - 1' : 'ever - repeated'$$

'ST001D01T':'international-Grade'

'ISCEDL': 'ISCEDlevel'

'ST005Q01TA':'mother-school'

'ST013Q01TA':'books-inroom'

'REPEAT':'REPEAT'

2 频繁项集

选择 FP-growth 算法^[1], 结果如图1:

```
{ frozenset({'REPEAT1.0'}): 1.0,
  frozenset({'REPEAT1.0', 'ever-repeated1'}): 1.0,
  frozenset({'REPEAT1.0', 'ISCED level2.0995'}): 0.8850442579606851,
  frozenset({'REPEAT1.0', 'ISCED level2.0995', 'ever-repeated1'}): 0.8850442579606851,
  frozenset({'REPEAT1.0', 'international-Grade8.5'}): 0.7535348890677089,
  frozenset({'REPEAT1.0', 'international-Grade8.5', 'ever-repeated1'}): 0.7535348890677089,
  frozenset({'REPEAT1.0', 'international-Grade8.5', 'ISCED level2.0995'}): 0.6777790550638004,
  frozenset({'REPEAT1.0', 'international-Grade8.5', 'ISCED level2.0995', 'ever-repeated1'}): 0.6777790550638004}
```

图 1: 频繁项集: 左边为频繁项集, 右边为支持度

说明:由于数据预处理使用了分箱均值去噪和均值填充空值,故结果可能与原来的整数值有一定偏差, 不过可以看到偏差并不大(因为在实验四中没有进行规范化处理),所以不影响本实验。

分析如下:

- (1) ever repeated1 作为一个相关系数为 1 的特征,自然会与 REPEAT 保持一致,复读的同学之前学习生涯中肯定复读过,这很合理。
- (2) *ISCED level* 指的是受教育水平, 2.0995 对应 *ISCED level* 2 左右, 这是一个中间值。可得结论: 受教育水平低的人读书时间短,复读的机会较少,当然也可能是因为他们在学习遇到困难时更倾向于辍学而不是复读;受教育水平高的人一般智商较高,虽然读书时间较长,可是其凭借自身天赋也能减少复读的概率;因此,处于中间的同学复读概率最大,其所在项集支持度也最高。
- (3) international Grade 指的是学生国际成绩, 8.5 对应 Grade 8 到 Grade 9 之间, 属于中等偏下的成绩。这是一个有迷惑性的结果, 初步看会以为是和 2 中 ISCED level 2.0995 一样的结论。其实不然, 通过 codebook 可以发现比该成绩区间低的成绩 Grade 7 仅占 0.75%, 所以其支持度小是由于其基数少而不是复读概率低。因此, 我们有结论: 成绩越低的学生复读的概率越大, 支持度越高, 这与学校挂科留级等制度相吻合。

3 关联规则

FP-growth 算法的关联规则发掘与 Apriori 算法是一样的:从顶向下,一步步生成候选集合再裁剪即可。结果如图2:

	antecedent	confidence	Lift	PS	coeficient
0	(ever-repeated1)	1.000000	4.839867	0.163927	1.000000
1	(ISCED level2.0995)	0.276128	1.336423	0.046033	0.240403
2	(ISCED level2.0995, ever-repeated1)	1.000000	4.839867	0.145082	0.926994
3	(international-Grade8.5)	0.849203	4.110031	0.117812	0.751995
4	(international-Grade8.5, ever-repeated1)	1.000000	4.839867	0.123524	0.841478
5	(ISCED level2.0995, international-Grade8.5)	0.878689	4.252735	0.107111	0.722769
6	(ISCED level2.0995, international-Grade8.5, ever-repeated1)	1.000000	4.839867	0.111106	0.790763

图 2: 关联规则

分析如下:

- (1) ever repeated1 仍然高居榜首,结论同1。在此不再重复。
- (2) ISCED level 2.0995 单独作为前件已经无法满足置信度要求,必须与其余二者结合才可以满足要求,这也说明它本身和 REPEAT 的关联性不是很强,并且与其余二者结合后反而降低了部分衡量指标,比如 (international Grade8.5, ISCED level2.0995, ever repeated1) 比 (international Grade8.5, ever repeated1) 的 PS coeficient 值要低。但是其与 international Grade8.5 集合时却显著提高了 antecedent confidence 这两个指标,考虑到正常情况下不会有 ever repeated 这么 bug 的特征存在,本实验还是认为 ISCED level2.0995 是一个优良的适合组合的特征。
- (3) *international—Grade*8.5 与 *REPEAT* 关联性较强,但是其与 *ever—repeated*1 集合的效果反而不如 (*ISCED level*2.0995, *ever—repeated*1),推测得到这可能是一个不太适合组合的特征。然瑕不掩瑜,同样的,考虑到正常情况下不会有 *ever—repeated* 这么 bug 的特征存在,*international—Grade*8.5 是我们正常情况下能找到的最佳单特征了。

4 辛普森悖论

将数据集分成不同国家的数据集,再次进行上述处理得到结果如图3。注:由于要寻找辛普森悖论现象, 本节取支持度阈值为 0.4,置信度阈值为 0.6。

分析如下:

- (1) 不同国家的频繁项集和关联规则差异还是比较大的。如 Chile 中 *ISCED level* 2.9 替代 *ISCED level* 2.0995 出现在了关联规则中,Dominican Republic 中 *books inroom* 1.4975 出现在了关联规则中。
- (2) 存在辛普森现象:在各个国家的关联规则中,(books inroom1.4975, international Grade8.5)的 置信度都大于(ISCED level2.0995, international Grade8.5)的置信度,但是在上一节中我们知

(a) 国家: Chile

(ever-repeated1, books-inroom1.4975) 1.000000 6.279379 0.090398 0.797516

(c) 国家: Dominican Republic

(e) 国家: Panama

```
国家188:
()
antecedent confidence Lift PS coeficient
```

(b) 国家: Costa Rica

(d) 国家: Mexico

(f) 国家: Spain

道,对于整个数据集,(ISCED level2.0995,international – Grade8.5)的置信度是大于(books – inroom1.4975,international—Grade8.5)的置信度的。寻找原因,应是(ISCED level2.0995,international—Grade8.5)在Spain中置信度很高,而且(ISCED level2.0995,international—Grade8.5,REPEAT1.0)在Spain 基数较大,数量较多导致的。

参考文献

- [1] Christian Borgelt. An implementation of the fp-growth algorithm. In *Proceedings of the 1st international workshop on open source data mining:*frequent pattern mining implementations, pages 1–5, 2005.
- [2] Liu Qi. Prof. qiliu's slides on ad2023. http://staff.ustc.edu.cn/~qiliuq1/files/AD2023/4.1.pdf.
- $[3] \ \ Liu\ Qi.\ Prof.\ qiliu'\ s\ slides\ on\ ad 2023.\ http://staff.ustc.edu.cn/~qiliuql/files/AD2023/4.2.pdf.$