中国科学技术大学

University of Science and Technology of China

# Lab 3


姓名：高茂航

学号：PB22061161


日期：2024.4.28

# Report 3

## 1 Task1

### 1.1 Algorithm Description

本节主要是调用了 pandas 库，对数据进行一系列处理，包括读取数据、查看数据的前 10 行、查看数据的信息、删除缺失值、重置索引、删除 id 列、查看 diagnosis 列的值的个数、将 diagnosis 列的值转换为 0 和 1、查看 2-7 列的统计信息、查看不同 diagnosis 值的各组数据所有特征的变异系数，详情在代码文件中显示。

### 1.2 Results

| | id | diagnosis | radius_mean | texture_mean | perimeter_mean | area_mean | \ |
|---|---|---|---|---|---|---|---|
| 0 | 842302 | M | 17.99 | 10.38 | 122.80 | 1001.0 | |
| 1 | 842517 | M | 20.57 | 17.77 | 132.90 | 1326.0 | |
| 2 | 84300903 | M | 19.69 | 21.25 | 130.00 | 1203.0 | |
| 3 | 84348301 | M | 11.42 | 20.38 | 77.58 | 386.1 | |
| 4 | 84358402 | M | 20.29 | 14.34 | 135.10 | 1297.0 | |
| 5 | 843786 | M | 12.45 | 15.70 | 82.57 | 477.1 | |
| 6 | 844359 | M | 18.25 | 19.98 | 119.60 | 1040.0 | |
| 7 | 84458202 | M | 13.71 | 20.83 | 90.20 | 577.9 | |
| 8 | 844981 | M | 13.00 | 21.82 | 87.50 | 519.8 | |
| 9 | 84501001 | M | 12.46 | 24.04 | 83.97 | 475.9 | |

| | smoothness_mean | compactness_mean | concavity_mean | concave points_mean | \ |
|---|---|---|---|---|---|
| 0 | 0.11840 | 0.27760 | 0.30010 | 0.14710 | |
| 1 | 0.08474 | 0.07864 | 0.08690 | 0.07017 | |
| 2 | 0.10960 | 0.15990 | 0.19740 | 0.12790 | |
| 3 | 0.14250 | 0.28390 | 0.24140 | 0.10520 | |
| 4 | 0.10030 | 0.13280 | 0.19800 | 0.10430 | |
| 5 | 0.12780 | 0.17000 | 0.15780 | 0.08089 | |
| 6 | 0.09463 | 0.10900 | 0.11270 | 0.07400 | |
| 7 | 0.11890 | 0.16450 | 0.09366 | 0.05985 | |
| 8 | 0.12730 | 0.19320 | 0.18590 | 0.09353 | |
| 9 | 0.11860 | 0.23960 | 0.22730 | 0.08543 | |

| | ... | radius_worst | texture_worst | perimeter_worst | area_worst | \ |
|---|---|---|---|---|---|---|
| ... | | | | | | |
| 0 | | 0.481809 | 0.154683 | | 0.173924 | |
| 1 | | 0.250869 | 0.232936 | | 0.236436 | |

[2 rows x 30 columns]

*Output is truncated. View as a scrollable element or open in a text editor. Adjust cell output settings...*

限于篇幅，没将 Task1 的全部结果显示出来。

## 2 Task2

### 2.1 Algorithm Description

本节调用了 numpy 和 matplotlib 库，对数据进行一系列处理，如绘制频率分布直方图、绘制分布散点图、corr() 求 Pearson 相关系数矩阵、用 matshow(corr, cmap='coolwarm') 绘

制相应的相关系数热力矩阵图等，由于都是固定的操作，故不再详述代码细节。

### 2.2 Results

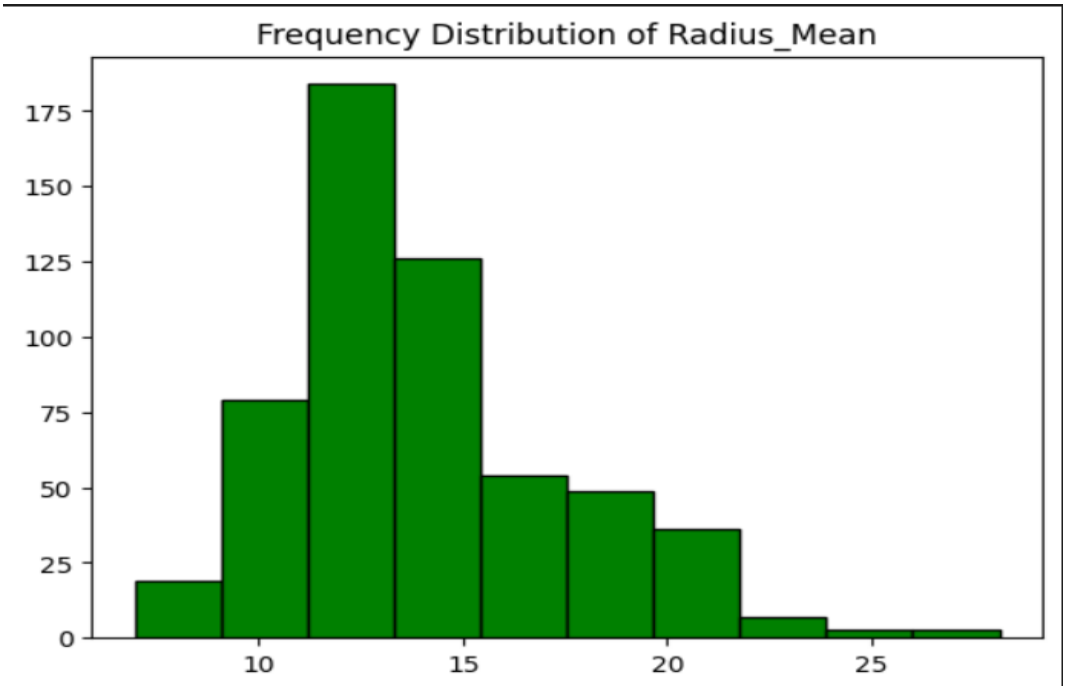

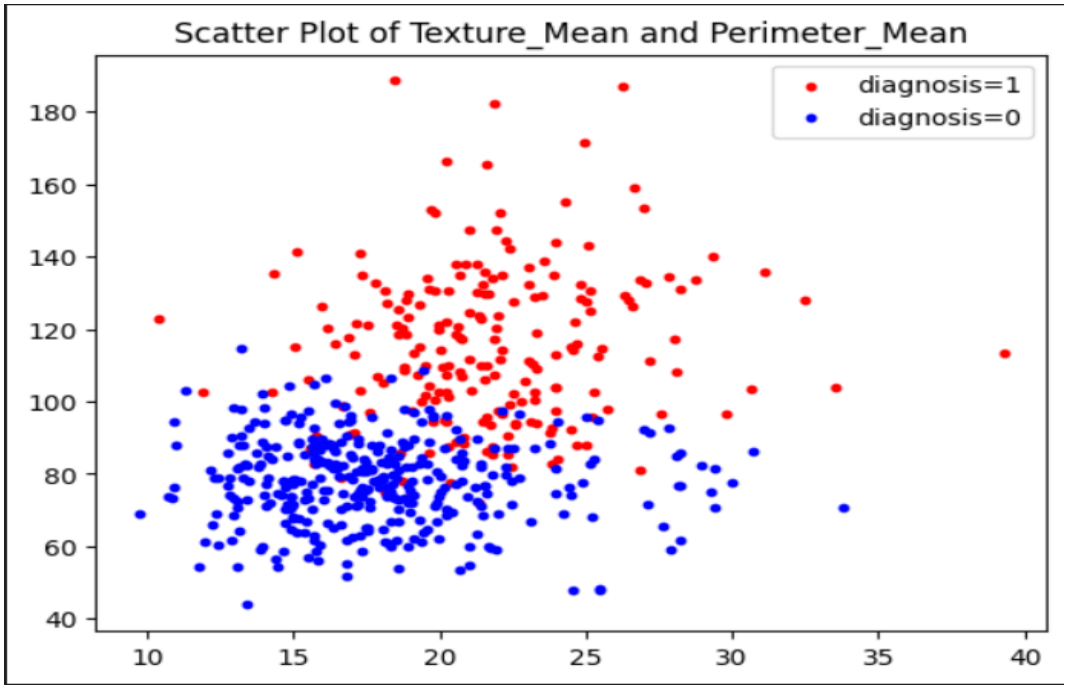


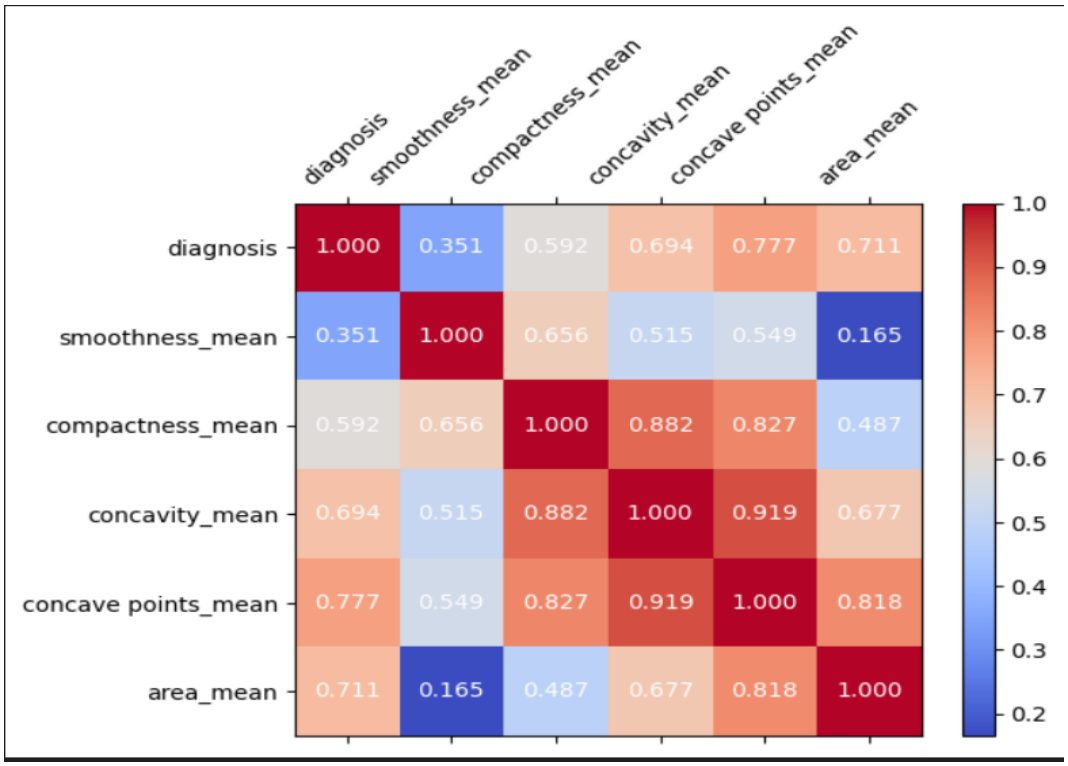


# 3 Task3

## 3.1 Algorithm Description

先用 np.column_stack() 将三个一维数组堆叠成一个二维数组，每个一维数组成为新二维数组的一列，进而代入公式求最小二乘估计，再使用 numpy.polyfit() 方法做二次多项式拟合，并绘制拟合曲线，可以发现数据适合二次函数拟合，而不适合线性拟合。

### 3.2 Results

```
Q1 Model parameters:  [ 3.14186228 -0.44260792 -4.70867951]
Q2 Model parameters:  [ 3.14186228 -0.44260792 -4.70867951]
omega - coeffs =  [-2.98872038e-13  7.63683561e-12 -4.56710225e-11]
```

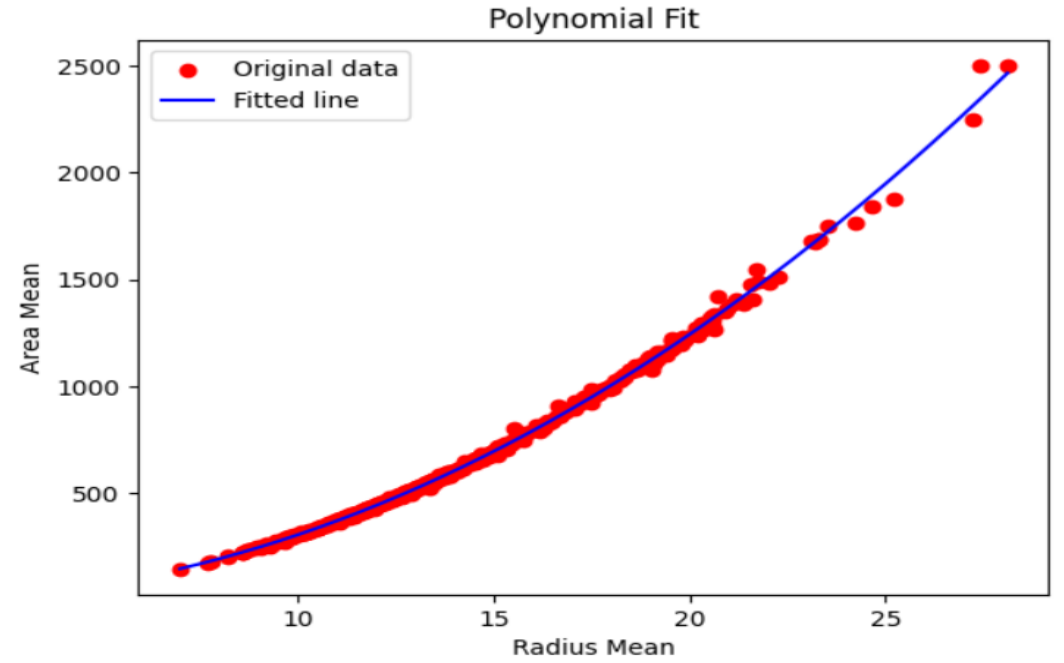


## 4 Task4

### 4.1 Algorithm Description

利用 numpy.cov() 和 numpy.linalg.eig() 求 X 的协方差矩阵 corX，进而求 corX 的特征值 eigV 与特征向量矩阵 eigMat，通过计算验证 eigMat 的正交性，接着对 X 进行 PCA，得到 Z，可以发现 Z 的数据的纵坐标基本在 0 附近，即 PCA 将 X 的数据映射到接近一维空间上。也能发现 cov(Z) 的对角元与 eigV 的值相等，且非对角元十分接近于 0。删除 Z 的一维数据，即可完成主成分分析降维过程。

### 4.2 Results

```
Eigenvalues:  [5.90457503e+02 5.21373729e-02]
Eigenvectors:
 [[ 0.98966947 -0.14336785]
 [ 0.14336785  0.98966947]]
Orthogonality check:  True
```

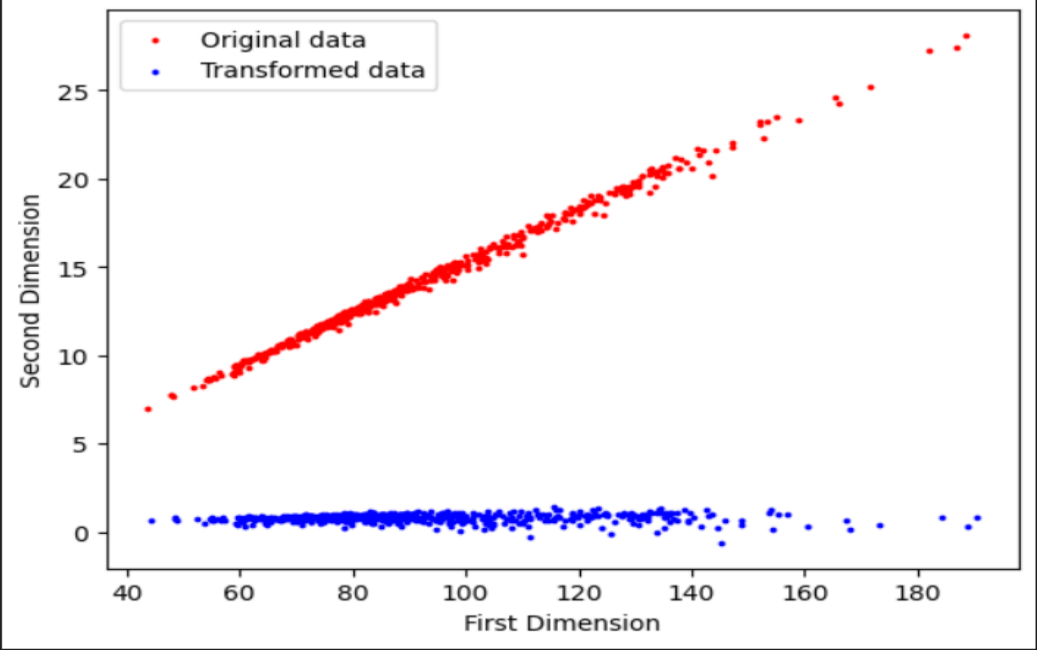


```
Covariance of Z:
 [[5.90457503e+02 1.97591893e-14]
 [1.97591893e-14 5.21373729e-02]]
Z_reduced :  [[124.11059852]
 [134.47614923]
 [131.47994405]
 [ 78.41581832]
 [136.61327906]
 [ 83.50193786]
 [120.98093186]
 [ 91.23375941]
 [ 88.45986066]
 [ 84.8889088 ]
 [103.93580752]
 [133.78059949]
 [104.90110445]
 [ 94.60150296]
 [ 97.81529636]
 [ 95.86592562]
 [109.29579312]
 [ 88.49769253]
```

限于篇幅，没将 Z_reduced 的全部结果显示出来。

# 5 Task5

## 5.1 Algorithm Description

本情景应该进行成组检验，因为两组数据相互独立，单侧检验原假设为 Mean of group1 = Mean of group2。因为 p 值为 5.469799049160595e-56 远小于 0.05，因此很有把握否认原假设，接受备择假设，即 Mean of group1 <= Mean of group2。

## 5.2 Results

```
Mean of group1:  0.1663615971830986
Mean of group2:  0.44671356097560977
t-statistic:  -19.01722049062515
p-value for one-tailed test:  5.469799049160595e-56
```