



中国科学技术大学  
University of Science and Technology of China

## Lab 4

### 乳腺癌数据集分析

姓名: 高茂航

学号: PB22061161

日期: 2024.5.16

# Report 4

## 1 Task1

### 1.1 Algorithm Description

使用 `df.isnull().sum()` 判断有缺失项的列, 使用 `df.dropna()` 删除有缺失项的行, 使用 `df.value_counts()` 显示一列中的数据分布, 快速找出异常项后用 `df.replace()` 替换为正常值, 等函数对数据集进行处理。

对于 Q3, 遍历 excel 文件每行的 Description 列的所有元素放到一个列表中, 以把 df 的值替换为索引, 但是处理时发现 deg-malig 是整数类型而非字符串, 因此一开始报错了, 后来将这列转为字符串类型后就可以了。此外, 还碰到一个问题是 node-caps 和 irradiat 这两列的值都是 yes/no, 一开始在替换时会把 node-caps 的索引赋给 irradiat, 因此在替换到 irradiat 时要特别找到第二个 yes/no 的索引。

### 1.2 Results

#### 1.2.1 Q1

```
id          0
Class       0
age         0
menopause   0
tumor-size  0
inv-nodes   0
node-caps   8
deg-malig   0
breast      0
breast-quad 1
irradiat    0
```

从结果可看出只有 node-caps 列和 breast-quad 列有缺失项, 因此删除了这两行。

#### 1.2.2 Q2

```
tumor-size
30-34      57
25-29      51
20-24      48
15-19      29
14-Oct      28
40-44      22
35-39      19
0-4         8
50-54       8
9-May       4
45-49       3
Name: count, dtype: int64
```

可看出 tumor-size 列有异常值 '14-Oct'、'9-May', 需要将其替换为正常值。

# Report 4

```
inv-nodes
0-2      209
5-Mar    34
8-Jun    17
11-Sep    7
15-17     6
14-Dec    3
24-26     1
Name: count, dtype: int64
```

可看出 `inv-nodes` 列有异常值 '5-Mar'、'8-Jun'、'11-Sep'、'14-Dec'，需要将其替换为正常值。

## 1.2.3 Q3

{0 : 'Class = no - recurrence - events', 1 : 'Class = recurrence - events', 2 : 'age = 10 - 19', 3 : 'age = 20 - 29', 4 : 'age = 30 - 39', 5 : 'age = 40 - 49', 6 : 'age = 50 - 59', 7 : 'age = 60 - 69', 8 : 'age = 70 - 79', 9 : 'age = 80 - 89', 10 : 'age = 90 - 99', 11 : 'menopause = lt40', 12 : 'menopause = ge40', 13 : 'menopause = premeno', 14 : 'tumor-size = 0-4', 15 : 'tumor-size = 5 - 9', 16 : 'tumor-size = 10 - 14', 17 : 'tumor-size = 15 - 19', 18 : 'tumor-size = 20 - 24', 19 : 'tumor-size = 25 - 29', 20 : 'tumor-size = 30 - 34', 21 : 'tumor-size = 35 - 39', 22 : 'tumor-size = 40 - 44', 23 : 'tumor-size = 45 - 49', 24 : 'tumor-size = 50 - 54', 25 : 'tumor-size = 55 - 59', 26 : 'inv-nodes = 0 - 2', 27 : 'inv-nodes = 3 - 5', 28 : 'inv-nodes = 6 - 8', 29 : 'inv-nodes = 9 - 11', 30 : 'inv-nodes = 12 - 14', 31 : 'inv-nodes = 15 - 17', 32 : 'inv-nodes = 18 - 20', 33 : 'inv-nodes = 21 - 23', 34 : 'inv-nodes = 24 - 26', 35 : 'inv-nodes = 27 - 29', 36 : 'inv-nodes = 30 - 32', 37 : 'inv-nodes = 33 - 35', 38 : 'inv-nodes = 36 - 39', 39 : 'node-caps = yes', 40 : 'node-caps = no', 41 : 'deg-malig = 1', 42 : 'deg-malig = 2', 43 : 'deg-malig = 3', 44 : 'breast = left', 45 : 'breast = right', 46 : 'breast-quad = left<sub>up</sub>', 47 : 'breast-quad = left<sub>low</sub>', 48 : 'breast-quad = right<sub>up</sub>', 49 : 'breast-quad = right<sub>low</sub>', 50 : 'breast-quad = central', 51 : 'irradiat = yes', 52 : 'irradiat = no'}

## 2 Task2

### 2.1 Algorithm Description

使用 Aprior 算法依次算出各个频繁项集，并根据关联规则算出置信度和提升度。具体过程是：先定义计算项集支持度的函数，然后定义产生候选项集的函数，最后写产生频繁项集的函数，依次产生各频繁项集。产生关联规则的思路主要是先找出所有含 0 的频繁项，在此基础上产生对应项去掉 0 后的集合以及只含有 0 的集合，就能计算它们的支持度，进而计算置信度和提升度。

本实验中再次使用了匿名函数，加深了对其的理解。

# Report 4

---

## 2.2 Results

### 2.2.1 Q1

Frequent 1-itemsets: [{0}, {12}, {13}, {26}, {40}, {42}, {44}, {45}, {52}]

Frequent 2-itemsets: [{40, 13}, {26, 13}, {40, 44}, {26, 44}, {0, 26}, {26, 52}, {0, 40}, {0, 52}, {40, 52}, {44, 52}, {52, 13}, {40, 26}]

Frequent 3-itemsets: [{0, 26, 52}, {0, 26, 40}, {0, 40, 52}, {40, 26, 52}]

Frequent 4-itemsets: [{0, 40, 26, 52}]

### 2.2.2 Q2

```
{26}->{0}: cof = 0.7942583732057417, lift = 1.122497802948931
{40}->{0}: cof = 0.7737556561085973, lift = 1.0935220241942931
{52}->{0}: cof = 0.7627906976744185, lift = 1.0780256288561936
{26, 52}->{0}: cof = 0.8166666666666667, lift = 1.1541666666666668
{40, 26}->{0}: cof = 0.7999999999999999, lift = 1.1306122448979592
{40, 52}->{0}: cof = 0.8074866310160427, lift = 1.1411928407726726
{40, 26, 52}->{0}: cof = 0.8238636363636364, lift = 1.1643378942486087
```

## 2.3 Conclusion

无结节帽、受侵淋巴结数目范围在 0-2 且未进行放疗与不复发强关联，我们可以认为出这部分患者不易复发乳腺癌。